

BREAST-CANCER

Progetto per “Ingegneria della Conoscenza”

AA 2024/2025

LINK REPOSITORY GITHUB:

<https://github.com/rafflog01/ICONProject>

REALIZZATO DA:

LOGLISCI RAFFAELE, 757060 ,

r.loglisci6@studenti.uniba.it

INDICE

#0 INTRODUZIONE	3
#1 DATASET	4
#1.1 DESCRIZIONE DATASET (DOMINIO)	4
#1.2 OSSERVAZIONE GRAFICA DEI DATI	6
#2 ONTOLOGIA	7
#2.1 ANALISI DOMINIO	7
#2.2 SOFTWARE PER LA REALIZZAZIONE DELL'ONTOLOGIA	7
#2.2.1 CLASSI	8
#2.2.2 OBJECT PROPERTY	9
#2.2.3 DATA PROPERTY	9
#2.2.4 INDIVIDUALS	10
#3 QUERY	10
#3.1 DL Query	10
#3.1 OwlReady2	11
#4 APPRENDIMENTO SUPERVISIONATO	12
#4.1 DECISIONI DI PROGETTO	12
#4.2 METRICHE	13
#4.2.1 DI VALIDAZIONE	13
#4.2.2 DI VALUTAZIONE	13
#4.3 SELEZIONE DELLE FEATURE	14
#4.4 PREPROCESSING DEI DATI	14
#4.4.1 DUMMIFICATION & LABEL ENCODING	14
#4.4.2 SMOTE	15
#4.4.3 STANDARDIZZAZIONE	15
#4.5 DIVISIONE DEI DATI	16
#4.6 K-NEAREST NEIGHBORS (K-NN)	17
#4.6.1 DECISIONI DI PROGETTO	17
#4.6.2 OTTIMIZZAZIONE DEL VALORE 'K'	17
#4.6.3 ADDESTRAMENTO	18
#4.6.4 PREDIZIONE	19
#4.6.5 VALUTAZIONE FINALE	19
#4.7 RANDOM FOREST	23
#4.7.1 DECISIONI DI PROGETTO	23
#4.7.2 OTTIMIZZAZIONE PARAMETRI DEL CLASSIFICATORE	23
#4.7.3 VALUTAZIONE FINALE	25
#4.8 SUPPORT VECTOR MACHINES (SVM)	27
#4.8.1. DECISIONI DI PROGETTO	27
#4.8.2 OTTIMIZZAZIONE PARAMETRO GAMMA	27
#4.8.3 VALUTAZIONE FINALE	29
#4.9 NEURAL NETWORK	31
#4.9.1 DECISIONI DI PROGETTO	31
#4.9.2 CREAZIONE MODELLO E ADDESTRAMENTO	31
#4.9.3 VALUTAZIONE FINALE	33
#4.10 CONCLUSIONI	34
#5 APPRENDIMENTO NON SUPERVISIONATO: CLUSTERING	36
#5.1 DECISIONI PROGETTUALI	36
#5.2 K-MEANS	37
#5.3 VALUTAZIONE FINALE DEL MODELLO	38
#6 CONCLUSIONE	40
#6.1 POSSIBILI SVILUPPI	40

#0 INTRODUZIONE

Il presente lavoro ha l'obiettivo di predire la diagnosi, di un cancro al seno, maligno o benigno sfruttando un DataSet disponibile online.

A tal proposito:

- È stata modellata un'[Ontologia](#) di riferimento che offre una rappresentazione formale e concettualizzata della realtà presa in esame, affinché possa venire interrogata tramite [Query](#).
- Sono state utilizzate tecniche di [Apprendimento Supervisionato](#) e [Non Supervisionato](#).

PROBLEMA IN QUESTIONE:

Il cancro al seno è il tumore più comune tra le donne al mondo. Rappresenta il 25% di tutti i casi di cancro e ha colpito oltre 2,1 milioni di persone solo nel 2015. Inizia quando le cellule del seno iniziano a crescere in modo incontrollato. Queste cellule di solito formano tumori visibili ai raggi X o palpabili come noduli nella zona del seno. La sfida principale per la sua individuazione è come classificare i tumori in maligni (cancerosi) e benigni (non cancerosi). Un tale DataSet può essere utilizzato per addestrare o utilizzare modelli e algoritmi per effettuare delle diagnosi.

MATERIALE UTILIZZATO:

LINGUAGGIO DI PROGRAMMAZIONE

- Python: <https://www.python.org/downloads/>

PROVIDER DEL DATASET

- cBioPortal: https://www.cbioportal.org/study/summary?id=breast_msk_2018

APP PER REALIZZAZIONE DELL'ONTOLOGIA

- Protégé: <https://protege.stanford.edu/>

LIBRERIE PYTHON

- Scikit-learn: <https://scikit-learn.org/>
- Pandas: <https://pandas.pydata.org/>
- Seaborn: <https://seaborn.pydata.org/>
- OwlReady2: <https://owlready2.readthedocs.io/en/v0.48/index.html>

#1 DATASET

Propongo l'utilizzo di un dataset relativo allo screening delle diagnosi di tumore al seno, reperito al seguente indirizzo: https://www.cbioportal.org/study/summary?id=breast_msk_2018.

#1.1 DESCRIZIONE DATASET (DOMINIO)

FEATURE: 59

CAMPIONE: 1918 istanze

FEATURE	FEATURE ROLE	DOMAIN TYPE	DESCRIPTION
Study ID	Feature	Continuous (0-3000)	Identificativo unico per riconoscere lo studio medico.
Patient ID	Feature	Continuous (0-3000)	Identificativo unico per riconoscere i pazienti.
Sample ID	Feature	Continuous (0-3000)	Codice identificativo del campione biologico analizzato.
Cancer Type	Feature	Continuous (0-3000)	Tipo generico di tumore.
Cancer Type Detailed	Feature	Continuous (0-3000)	Tipo di tumore con classificazione specifica.
Disease Free Event	Feature	Binary (0/1)	Evento che indica una ricaduta o progressione della malattia.
Disease Free (Months)	Feature	Continuous (0-3000)	Mesi trascorsi senza segni di malattia.
ER PCT Primary	Feature	Integer (0-80000)	Percentuale di recettori estrogeni nel tumore primario.
ER Status of Sequenced Sample	Feature	Continuous (0-3000)	Stato dei recettori estrogeni nel campione sequenziato.
ER Status of the Primary	Feature	Binary (0/1)	Stato dei recettori estrogeni nel tumore primario.
Fraction Genome Altered	Feature	Continuous (0-3000)	Frazione del genoma con alterazioni somatiche.
HER2 FISH Status of Sample	Feature	Continuous (0-3000)	Stato HER2 tramite FISH nel campione sequenziato.
HER2 IHC Status Primary	Feature	Continuous (0-3000)	Stato HER2 rilevato tramite IHC nel tumore primario.
HER2 IHC Score of Sequenced Sample	Feature	Continuous (0-3000)	Punteggio IHC HER2 del campione sequenziato.
HER2 IHC Score Primary	Feature	Continuous (0-3000)	Punteggio IHC HER2 nel tumore primario.
HER2 Primary Status	Feature	Continuous (0-3000)	Stato finale HER2 del tumore primario.
Overall HR Status of Sequenced Sample	Feature	Continuous (0-3000)	Stato complessivo dei recettori ormonali nel campione sequenziato.


Invasive Carcinoma Diagnosis Age	Feature	Integer (0-80000)	Età alla diagnosi di carcinoma invasivo.
Prior Breast Primary	Feature	Binary (0/1)	Presenza di precedenti tumori mammari.
Prior Local Recurrence	Feature	Binary (0/1)	Presenza di recidive locali precedenti.
Primary Tumor Laterality	Feature	Continuous (0-3000)	Lato del corpo in cui si trova il tumore primario (es. sinistro o destro).
PR Status of the Primary	Feature	Continuous (0-3000)	Stato PR del tumore primario.
M Stage	Feature	Continuous (0-3000)	Stadio di metastasi (M) secondo la classificazione TNM.
Menopausal Status At Diagnosis	Feature	Continuous (0-3000)	Stato menopausale alla diagnosi.
Metastatic Disease at Last	Feature	Binary (0/1)	Presenza di metastasi all'ultimo follow-up.
Metastatic Recurrence Time	Feature	Integer (0-80000)	Tempo alla ricomparsa metastatica.
Mutation Count	Feature	Integer (0-80000)	Numero totale di mutazioni somatiche rilevate.
N Stage	Feature	Continuous (0-3000)	Stadio dei linfonodi (N) nella classificazione TNM.
NGS Sample Collection Time Period	Feature	Integer (0-80000)	Periodo di raccolta dei campioni per NGS (Next-Gen Sequencing).
Oncotree Code	Feature	Continuous (0-3000)	Codice standardizzato della classificazione OncoTree del tumore.
Overall Survival (Months)	Feature	Integer (0-80000)	Sopravvivenza complessiva in mesi.
Overall Primary Tumor Grade	Feature	Integer (0-80000)	Grado istologico del tumore primario.
Patient's Vital Status	Feature	Continuous (0-3000)	Stato vitale del paziente (vivo/deceduto).
Sample Type	Feature	Continuous (0-3000)	Tipo di tessuto analizzato (es. biopsia, chirurgico).
Overall Survival Status	Target	Binary (0 / 1)	Stato di sopravvivenza del paziente (vivo/deceduto).

#1.2 OSSERVAZIONE GRAFICA DEI DATI

Ho effettuato un'analisi visiva dei dati con l'**obiettivo** di individuare eventuali **correlazioni** tra le **variabili** e comprendere in che misura **influenzano** lo stato di vita. I **numeri** visibili su ogni cella della heatMap sono i **valori di correlazione** con un valore vicino ad **1** abbiamo una **forte correlazione**, al crescere di una variabile cresce anche l'altra, vicino allo **0** **nessuna correlazione** mentre vicina a **-1** abbiamo una **forte correlazione negativa**, al crescere di una variabile l'altra diminuisce. Di seguito una heatmap generata tramite Python a supporto di questa analisi:

MATRICE DI CORRELAZIONE

Una **matrice di correlazione** è un insieme di valori numerici che esprimono **relazioni** tra le **feature** del DataSet. La visualizzazione di questa matrice viene comunemente realizzata tramite una **heatmap**, facilmente generabile con la libreria **Seaborn** in Python, che consente di interpretare visivamente le correlazioni attraverso una scala di colori.



#2 ONTOLOGIA

Un'**Ontologia** rappresenta in modo strutturato la **conoscenza** relativa a un determinato dominio. In termini semplici, si tratta di un sistema per **organizzare** e definire **concetti** e **relazioni** tra essi in maniera chiara e formale.

L'analisi del dominio consente di individuare i **concetti fondamentali**, le relazioni che li legano e le proprietà che li descrivono.

Una volta identificate, queste informazioni possono essere **formalizzate** utilizzando un linguaggio apposito, come **OWL (Ontology Web Language)**.

#2.1 ANALISI DOMINIO

Ho deciso di dividere gli attributi del DataSet in:

- ***"ciò che deve essere rappresentato"***:
Gli attributi fondamentali e cruciali che devono essere rappresentati per catturare le informazioni essenziali dal DataSet.
 - Nel nostro contesto si parla di Pazienti, Diagnosi, Tumore, Sample, AltaProbabilitaSopravvivenza, BassaProbabilitaSopravvivenza e PazienteAltoRischioRecidiva.
- ***"ciò che caratterizza ciò che deve essere rappresentato"***:
Le proprietà delle entità rappresentate.
 - Nel caso del Tumore, ad esempio, possono essere area, perimetro, etc.

#2.2 SOFTWARE PER LA REALIZZAZIONE DELL'ONTOLOGIA


L'ontologia è stata sviluppata utilizzando **Protégé**, un software open-source ampiamente utilizzato per la **creazione e gestione di ontologie**.

Protégé consente di definire concetti, classi e relazioni in modo strutturato, supportando standard come **OWL (Web Ontology Language)** per la rappresentazione formale della conoscenza.

#2.2.1 CLASSI

Ho deciso di rappresentare come **Classi/Entity** dell'ontologia:

- **Paziente:**
Rappresenta l'insieme dei pazienti sottoposti al test.
A questa classe ho associato un'unica proprietà:
 - PatientID: identificativo unico per il riconoscimento
- **Diagnosi:**
Rappresenta la diagnosi del paziente riguardante il cancro al seno che ha come proprietà:
 - stageAtDiagnosis: Stadio clinico al momento della diagnosi.
- **Tumore:**
Rappresenta il cancro al seno diagnosticato ai vari pazienti a cui vengono associati i valori visivi e i vari biomarkers:
 - her2FISHRatioPrimary
 - ...
- **Sopravvivenza:**
Rappresenta lo stato di sopravvivenza complessivo del paziente e tra le varie feature la principale è il target ovvero 'Overall Survival Status'
- **Sample:**
Rappresenta un campione biologico prelevato da un paziente per analisi cliniche/molecolari che vengono identificati con sampleId
Le successive 3 classi sono inferenziali ottenute da regole **SWRL**; gli individui vi vengono classificati solo dopo l'esecuzione del reasoner (Pellet)
- **AltaProbabilitaSopravvivenza:**
(ageAtDiagnosis<=45 and mutationCount<3 and (priorBreastPrimary=false or priorLocalRecurrence=false))
Rappresenta la categoria di pazienti con prognosi favorevole secondo criteri/indicatori clinici.
- **BassaProbabilitaSopravvivenza:**
(ageAtDiagnosis>=50 and mutationCount>=3 and (priorBreastPrimary=true or priorLocalRecurrence=true))
categoria di pazienti con prognosi sfavorevole secondo criteri/indicatori clinici.
- **PazienteAltoRischioRecidiva:**
(ageAtDiagnosis<=50 and mutationCount>=5 and (priorBreastPrimary=true or priorLocalRecurrence=true))
pazienti con elevata probabilità di recidiva sulla base di regole/feature cliniche.



Active ontology		Entities	Individuals by class	DL Query	SWRLTab
		Rule			
☒	...	untitled-ontology-5:Paziente(?p) ^ untitled-ontology-5:ageAtDiagnosis(?p, ?a) ^ swrlb:lessThanOrEqual(?a, 50) ^ untitled-ontology-5:mutationCount(?p, ?m) ^ swrlb:lessThanOrEqual(?m, 3) ^ (untitled-ontology-5:priorBreastPrimary=?p, false) ^ (untitled-ontology-5:priorLocalRecurrence=?p, false)			
☒	...	untitled-ontology-5:Paziente(?p) ^ untitled-ontology-5:ageAtDiagnosis(?p, ?a) ^ swrlb:lessThanOrEqual(?a, 45) ^ untitled-ontology-5:mutationCount(?p, ?m) ^ swrlb:lessThanOrEqual(?m, 3) ^ (untitled-ontology-5:priorBreastPrimary=?p, false) ^ (untitled-ontology-5:priorLocalRecurrence=?p, false)			
☒	...	untitled-ontology-5:Paziente(?p) ^ untitled-ontology-5:ageAtDiagnosis(?p, ?a) ^ swrlb:greaterThanOrEqual(?a, 50) ^ untitled-ontology-5:mutationCount(?p, ?m) ^ swrlb:greaterThanOrEqual(?m, 3) ^ (untitled-ontology-5:priorBreastPrimary=?p, true) ^ (untitled-ontology-5:priorLocalRecurrence=?p, true)			
☒	...	untitled-ontology-5:Paziente(?p) ^ untitled-ontology-5:ageAtDiagnosis(?p, ?a) ^ swrlb:greaterThanOrEqual(?a, 50) ^ untitled-ontology-5:mutationCount(?p, ?m) ^ swrlb:greaterThanOrEqual(?m, 5) ^ (untitled-ontology-5:priorBreastPrimary=?p, true) ^ (untitled-ontology-5:priorLocalRecurrence=?p, true)			
☒	...	untitled-ontology-5:Paziente(?p) ^ untitled-ontology-5:ageAtDiagnosis(?p, ?a) ^ swrlb:lessThanOrEqual(?a, 50) ^ untitled-ontology-5:mutationCount(?p, ?m) ^ swrlb:lessThanOrEqual(?m, 3) ^ (untitled-ontology-5:priorBreastPrimary=?p, false) ^ (untitled-ontology-5:priorLocalRecurrence=?p, false)			



#2.2.2 OBJECT PROPERTY

Una **object property** consente di stabilire una **relazione tra due individui**, che possono appartenere sia a classi differenti sia alla stessa classe.

Queste proprietà descrivono **legami strutturali** all'interno dell'ontologia, contribuendo a definire la semantica delle interazioni tra entità.

Tra le classi ho definito 4 relazioni (con i rispettivi inversi) che rappresentano come queste interagiscono tra di loro. Le relazioni in questione sono:

- **hasDiagnosis (Paziente -> Diagnosi)** Significato: **un paziente ha una diagnosi.**
- **hasSample (Paziente -> Sample)** Significato: **campione appartiene a un paziente**
- **hasTumor (Sample -> Tumore)** Significato: **campione può essere associato a un un tumore**
- **hasSurvivalEvent (Paziente -> Sopravvivenza)** Significato: **Si può risalire dal dato di sopravvivenza al paziente di riferimento.**



#2.2.3 DATA PROPERTY

Una **data property** definisce attributi o informazioni specifiche associate a un'istanza, mette in relazione un individuo con un valore primitivo.

#2.2.4 INDIVIDUALS

Per alcune entità ho inserito delle **istanze (individuals)**, alcune ad esempio per individuare una tipologia di esame come quella istologica, altre per individuare istanze di persone a cui attribuire un cancro, ed effettuare prove di query DL

Individuals:
◆+ ✕
◆ Diag_0000004
◆ Diag_0000015
◆ Diag_0000129
◆ Diag_0001114
◆ P-0000004
◆ P-0000004-T01-IM3
◆ P-0000015
◆ P-0000015-T01-IM3
◆ P-0000129
◆ P-0000129-T01-IM3
◆ P-0000158
◆ P-0000806
◆ P-0001114
◆ P-0001114-T02-IM3
◆ Surv_0000004
◆ Surv_0000015
◆ Surv_0000129
◆ Surv_0001114
◆ Tumor_0000004
◆ Tumor_0000015
◆ Tumor_0000129
◆ Tumor_0001114

Property assertions: P-0000129
+
Object property assertions +
■ hasSample P-0000129-T01-IM3
■ hasSurvivalEvent Surv_0000129
Data property assertions +
■ ageAtDiagnosis 46
■ mutationCount 1
■ ngsSampleCollectionPeriod 576
■ numberOfSamplesPerPatient 1
■ patientID "P-0000129"
■ priorBreastPrimary false
■ priorLocalRecurrence false
■ sex "Female"
■ vitalStatus "Deceased"

#3 QUERY

#3.1 DL Query

Interrogo l'ontologia tramite **DL - Descriptions Logics**, che e' un linguaggio formale utilizzato principalmente per la modellazione concettuale e l'ontologia nelle discipline dell'intelligenza artificiale e della rappresentazione della conoscenza.

QUERY REALIZZATE:

DL query:
Query (class expression)
Tumore and isTumorOfSample some (isSampleOf some Paziente)
Execute Add to ontology
Query results
Instances (4 of 4)
◆ Tumor_0000004
◆ Tumor_0000015
◆ Tumor_0000129
◆ Tumor_0001114

DL query:
Query (class expression)
Tumore and hasDiagnosis some (Diagnosi and stageAtDiagnosis value "IV")
Execute Add to ontology
Query results
Instances (2 of 2)
◆ Tumor_0000004
◆ Tumor_0000129

#3.1 OwlReady2

È stato poi creato il file “ontology_query.py” con il quale è possibile consultare l’ontologia direttamente in Python grazie alla libreria **OwlReady2** per la manipolazione di ontologie e il ragionamento.

Con il seguente codice è quindi possibile estrarre dall’ontologia la lista di [classi](#), [object property](#), [data property](#) e [query](#).

```
#####
LISTA CLASSI DELL'ONTOLOGIA

• CLASSE: AltaProbabilitaSopravvivenza
• CLASSE: BassaProbabilitaSopravvivenza
• CLASSE: Diagnosi
• CLASSE: Paziente
• CLASSE: PazienteAltoRischioRecidiva
• CLASSE: Sample
• CLASSE: Sopravvivenza
• CLASSE: Tumore

#####
LISTA OBJECT PROPERTIES DELL'ONTOLOGIA

• OBJECT PROPERTY: hasDiagnosis
• OBJECT PROPERTY: hasSample
• OBJECT PROPERTY: hasSurvivalEvent
• OBJECT PROPERTY: hasTumor
• OBJECT PROPERTY: isDiagnosisOf
• OBJECT PROPERTY: isSampleOf
• OBJECT PROPERTY: isSurvivalOf
• OBJECT PROPERTY: isTumorOfSample

#####
LISTA DATA PROPERTIES DELL'ONTOLOGIA

• DATA PROPERTY: ageAtDiagnosis
• DATA PROPERTY: cancerType
• DATA PROPERTY: cancerTypeDetailed
• DATA PROPERTY: diseaseFreeEvent
• DATA PROPERTY: diseaseFreeMonths
• DATA PROPERTY: erPctPrimary
• DATA PROPERTY: erStatusOfPrimary
• DATA PROPERTY: erStatusOfSequencedSample
• DATA PROPERTY: her2FISHRatioPrimary
• DATA PROPERTY: her2FISHRatioSequencedSample
• DATA PROPERTY: her2FISHStatusPrimary
• DATA PROPERTY: her2FISHStatusSequencedSample
• DATA PROPERTY: her2IHCStatusPrimary
• DATA PROPERTY: her2IHCStatusSequencedSample
• DATA PROPERTY: her2IHCStatusSequencedSample
• DATA PROPERTY: her2PrimaryStatus
• DATA PROPERTY: hrStatusOfPrimary
• DATA PROPERTY: hrStatusOfSequencedSample
• DATA PROPERTY: lastCommunicationContact
• DATA PROPERTY: mStage
• DATA PROPERTY: menopausalStatusAtDiagnosis
• DATA PROPERTY: metastaticDiseaseAtLastFollowUp
• DATA PROPERTY: metastaticRecurrenceTime
• DATA PROPERTY: mutationCount
• DATA PROPERTY: nStage
• DATA PROPERTY: ngsSampleCollectionPeriod
• DATA PROPERTY: numberOfSamplesPerPatient
• DATA PROPERTY: oncotreeCode
• DATA PROPERTY: overallHER2Status
• DATA PROPERTY: overallPatientHER2Status
• DATA PROPERTY: overallPatientHRStatus
• DATA PROPERTY: overallPatientReceptorStatus
• DATA PROPERTY: overallSurvivalMonths
• DATA PROPERTY: overallSurvivalStatus
• DATA PROPERTY: patientID
• DATA PROPERTY: prPctPrimary
• DATA PROPERTY: prStatusOfPrimary
• DATA PROPERTY: prStatusOfSequencedSample
• DATA PROPERTY: primaryNuclearGrade
• DATA PROPERTY: primaryTumorLaterality
• DATA PROPERTY: priorBreastPrimary
```

```
• DATA PROPERTY: priorLocalRecurrence
• DATA PROPERTY: receptorStatusPrimary
• DATA PROPERTY: sampleId
• DATA PROPERTY: sampleType
• DATA PROPERTY: sex
• DATA PROPERTY: siteOfSample
• DATA PROPERTY: stageAtDiagnosis
• DATA PROPERTY: studyID
• DATA PROPERTY: tStage
• DATA PROPERTY: timeToDeathMonths
• DATA PROPERTY: timeToDiagnosis
• DATA PROPERTY: tmbNonsynonymous
• DATA PROPERTY: tumorGrade
• DATA PROPERTY: tumorSampleHistology
• DATA PROPERTY: tumorTissueOrigin
• DATA PROPERTY: vitalStatus
```

```
##### QUERY ESEMPI #####
```

```
Pazienti con ALTA PROBABILITA' DI SOPRAVVIVENZA:
• PAZIENTE: P-0000158
```

```
Pazienti con BASSA PROBABILITA' DI SOPRAVVIVENZA:
• PAZIENTE: P-0000806
• PAZIENTE: P-0001114
```

```
Pazienti ad ALTO RISCHIO DI RECIDIVA:
• PAZIENTE: P-0001114
```

```
NUMERO DI TUMORI PRESENTI: 4
```

```
• TUMORE: Tumor_0000004
• TUMORE: Tumor_0000015
• TUMORE: Tumor_0000129
• TUMORE: Tumor_0001114
```

```
Process finished with exit code 0
```

#4 APPRENDIMENTO SUPERVISIONATO

L'apprendimento supervisionato è una forma di apprendimento automatico in cui un modello viene addestrato su un insieme di dati etichettati, cioè contenenti input accompagnati dai rispettivi output corretti.

Lo scopo è permettere al modello di apprendere le relazioni tra input e output, così da poter effettuare previsioni accurate su dati mai visti prima.

In base alla natura del problema, l'apprendimento supervisionato può essere utilizzato per: **Classificazione**, quando gli output appartengono a un insieme discreto e finito di categorie; **Regressione**, quando gli output sono valori continui.

Durante la fase di addestramento, il modello cerca di riconoscere pattern e regolarità nei dati. In seguito, viene testato su dati non utilizzati in fase di training per valutare la sua capacità di generalizzare, distinguendo così un apprendimento reale da una semplice memorizzazione.

#4.1 DECISIONI DI PROGETTO

In questo progetto, l'obiettivo affidato all'apprendimento supervisionato è risolvere un **problema di classificazione**.

Ho utilizzato la colonna "*Overall Survival Status*" del DataSet come **variabile target** da predire basandosi sulle altre caratteristiche dei pazienti.

La prima cosa che ho fatto è stata decidere quali modelli di apprendimento supervisionato utilizzare.

Data l'elevata sensibilità del tema, quale lo stato di un tumore, era essenziale adottare algoritmi che garantissero alte prestazioni e precisione nelle previsioni, perciò ho scelto il **KNN** visto che è un algoritmo non parametrico facilmente interpretabile, fondamentale in ambito medico dove la trasparenza delle decisioni è cruciale per l'accettazione clinica, successivamente **Random Forest** e **Neural Network**; il primo principalmente perché fornisce automaticamente un ranking dell'importanza delle variabili, cruciale per identificare i fattori prognostici più rilevanti per la sopravvivenza nel cancro al seno e il secondo per la scalabilità ovvero che se in futuro il dataset dovesse espandersi con più variabili (es. dati genomici, imaging), le neural network possono facilmente adattarsi.

RECAP MODELLI REALIZZATI:

1. [K NN - K Nearest Neighbors](#)
2. [Random Forest](#)
3. [Neural Network](#)
4. [SVM](#)

#4.2 METRICHE

Andiamo adesso ad analizzare le metriche con cui sono stati valutati i modelli ed i risultati.

#4.2.1 DI VALIDAZIONE

La **cross-validation** è una tecnica comunemente utilizzata per valutare le **prestazioni** dei modelli in modo più **accurato** e **affidabile**, riducendo il rischio di risultati distorti dovuti alla suddivisione casuale dei dati inoltre valuta quanto un modello di machine learning generalizza bene su dati mai visti prima, evitando di sovraccaricarsi (overfitting) o di imparare troppo poco.

In questo lavoro, per la scelta degli iper-parametri (grazie alla funzione StratifiedKfold) ho utilizzato una tecnica di K-Fold Cross Validation (CV). Ho scelto di applicare una in ogni modello una **5-fold cross-validation**, suddividendo il dataset in cinque sottoinsiemi di pari dimensione. Il modello viene quindi addestrato e testato cinque volte, utilizzando ogni volta una fold diversa come set di test e le rimanenti come set di addestramento.

La **valutazione del modello** sarà basata sui risultati ottenuti durante la **cross-validation**: alcune metriche verranno calcolate sulla **migliore** delle cinque iterazioni, altre, invece, rifletteranno le **prestazioni medie** complessive su tutte le iterazioni.

La strategia che ho deciso di applicare per ricercare gli iper-parametri dei miei modelli è la **GridSearch** con Cross Validation. In questo approccio vengono definite le griglie dei valori possibili per gli iper-parametri e si esplorano tutte le combinazioni possibili alla ricerca della miglior combinazione possibile.

#4.2.2 DI VALUTAZIONE

Per ogni algoritmo implementato sono stati prodotti 2 tipologie di grafici differenti:

- **Bar Chart di Varianza e Deviazione Standard:**
Questo tipo di grafico a barre rappresenta la **Varianza** e la **Deviazione Standard** dei punteggi di **cross-validation**.
Aiutano a comprendere quanto i risultati siano consistenti o variabili su diverse iterazioni della cross-validation.
- **Stampa finale di alcune metriche:**
Classification Report e dei risultati stampati nel terminale:
esplorazione del DataSet, cv_scores_mean, cv_scores_variance, accuracy score, cv_score_devstandard, AUC e f1_score.

#4.3 SELEZIONE DELLE FEATURE

FEATURES SELEZIONATE:

La selezione e' stata fatta scegliendo le feature piu' importanti e impattanti scartando quelle rappresentavano date o identificativi.

FEATURES SCARTATE:

"Study ID", "Patient ID", "Sample ID", "Cancer Type", "Cancer Type Detailed", "Site of Sample", "Sample Type", "Sex", "Tumor Sample Histology", "Tumor Tissue Origin", "Last Communication Contact", "Oncotree Code"

#4.4 PREPROCESSING DEI DATI

L'addestramento di ogni modello inizia con l'esecuzione del Preprocessing dei dati.

#4.4.1 DUMMIFICATION (ONE-HOT ENCODING) & IMPUTER

La **dummification** è una fase del preprocessing che consiste nella trasformazione di feature categoriche in **feature numeriche**.

In particolare, ogni valore possibile di una variabile categorica (cioè ogni categoria) viene convertito in una nuova feature binaria, che assume valore 1 se la categoria è presente e 0 altrimenti. Un esempio e' il **one-hot encoding**, che viene fatto prima dello split per evitare data leakage, esso crea una colonna binaria per ogni categoria (k colonne per k categorie) ma non introduce ordine tra categorie.

Mentre l'**imputazione** serve a gestire i valori mancanti (NaN) nelle feature prima di addestrare/valutare i modelli e perciò ad evitare errori e perdita di dati; ciò viene eseguito grazie a **SimpleImputer** che sostituisce i NaN numerici prima di SMOTE/scaling/modello, quindi impedisce che rimangano valori mancanti nelle feature durante il fit/predict.

#4.4.2 SMOTE

La funzione **SMOTE()**, implementabile grazie all'uso della libreria **imblearn**, ha lo scopo di ridimensionare la classe di esempi quando si lavora con DataSet sbilanciati, dove una classe è rappresentata in modo significativamente minore rispetto all'altra classe, la conseguenza è che i modelli di machine learning possono venire "ingannati" dalla classe più numerosa e imparano a predire quasi sempre quella, ignorando la minoritaria.

Il dataset iniziale era **sbilanciato** con il 73% di pazienti vivi e il 27% di pazienti morti perciò sono stato costretto ad utilizzare la funzione SMOTE. Questa funzione si applica solo ed esclusivamente sul **trainSet** per evitare il **data leakage**.

#4.4.3 STANDARDIZZAZIONE

Ho utilizzato la funzione **StandardScaler()** della libreria **scikit-learn** per standardizzare le feature, ovvero portarle tutte sulla **stessa scala**.

Questo passaggio è importante per evitare che variabili con scale diverse **influenzino** in modo sproporzionato l'addestramento dei modelli, specialmente quelli sensibili alle distanze tra le osservazioni.

In particolare:

La standardizzazione è fondamentale per modelli che si basano direttamente sul calcolo di distanze o prodotti scalari.

#4.5 DIVISIONE DEI DATI

SUDDIVISIONE DATASET: **80% TrainSet – 20% TestSet.**

Questa suddivisione è sembrata un **buon compromesso** tra l'esigenza di disporre di un numero sufficiente di dati per l'addestramento e quella di valutare in modo affidabile le prestazioni del modello.

Dopo aver diviso l'intero DataSet in train e test, il training set l'ho **suddiviso** in **training** e **validation**.

Successivamente volevo che i risultati finali si fossero basati al **variare** di **diversi test set** e per fare cio' ho inserito nell'outer loop la suddivisione in 80/20 fatta per 10 volte (ripete più volte lo split) e, dentro ogni run, una 5-fold CV per il tuning tramite GridSearchCV.

- **Con una proporzione maggiore per il Test Set:** il modello avrebbe avuto meno dati su cui allenarsi, riducendo la sua capacità di apprendere le caratteristiche più complesse del dataset. Questo avrebbe potuto compromettere la sua capacità di generalizzare in modo efficace.
- **Con una proporzione maggiore per il Train Set:** si sarebbe corso il rischio di **overfitting**, ovvero che il modello imparasse anche il rumore e le particolarità dei dati di addestramento, con conseguente riduzione della capacità di adattarsi a nuovi dati.

#4.6 K-NEAREST NEIGHBORS (K-NN)

L'algoritmo alla base di questo metodo è il **Nearest Neighbor (NN)**, un approccio di classificazione che assegna a un dato in input la classe dell'esempio **più simile** presente nel dataset.

La similarità tra i dati viene misurata utilizzando una metrica, come ad esempio la **distanza euclidea**.

Il **K-Nearest Neighbors (K-NN)** rappresenta un'estensione del NN: invece di considerare un solo vicino, prende in esame i **K esempi più vicini** e assegna al dato in input la classe più frequente tra essi.

Questo consente di ottenere una classificazione più stabile e robusta, specialmente in presenza di rumore o dati ambigui.

#4.6.1 DECISIONI DI PROGETTO

Ho scelto di implementare inizialmente il modello **K-NN** perché risulta semplice da realizzare, flessibile e adatto a dataset di diverse dimensioni. Inoltre, si è dimostrato particolarmente **robusto** in presenza di rumore o valori anomali, poiché la classificazione finale si basa sui dati circostanti: ciò limita l'influenza di eventuali outlier sul risultato complessivo.

#4.6.2 OTTIMIZZAZIONE DEL VALORE 'K'

In genere:

- Valori di K troppo piccoli portano a problemi di **overfitting**.
- Valori di K troppo grandi portano a problemi di **underfitting**.

Per trovare il **valore ottimale** di K (numero di vicini) si itera per k da 1 a 20.

Per ogni k si:

- Crea un classificatore K-NN con k vicini.
- si calcola `pred_i` e si confronta con le etichette reali.
- `np.mean(pred_i != y_test)` misura la percentuale di errori e la aggiunge a `error`.
- Effettua previsioni su `X_test`.
- Scelta k ottimale → si trova `min(error)`, si ricava l'indice e si aggiunge +1 per ottenere il k corretto che nel mio caso è 5.

#4.6.3 ADDESTRAMENTO

Creiamo il nostro classificatore con **k** vicini.

Usiamo il metodo `fit()` in **scikit-learn** per addestrare un modello sui dati forniti.

A differenza di altri algoritmi di machine learning il K-NN non apprende un modello matematico basato sui dati di training ma memorizza semplicemente i dati di training.

#4.6.4 PREDIZIONE

Uso il metodo `predict()` in **scikit-learn** per fare **previsioni** su ogni dato del TestSet basandosi sulle informazioni apprese dal modello addestrato in precedenza.


Vado poi a calcolare l'**accuratezza** facendo il rapporto tra il numero di previsioni corrette e il numero totale di previsioni effettuate.

Usiamo quindi il metodo `accuracy_score()` in **scikit-learn** che restituisce la percentuale di previsioni corrette sul TestSet.

#4.6.5 VALUTAZIONE FINALE

BAR CHART DI VARIANZA E DEVIAZIONE STANDARD

Il grafico indica una bassa dispersione nei risultati del modello. Ciò suggerisce che il modello ha performance stabili e costanti attraverso le diverse esecuzioni, con fluttuazioni minime nelle sue predizioni.



=== Riepilogo Repeated Holdout (outer test) con inner 5-fold CV ===

Accuracy: mean=0.8995 | std=0.0101 | var=0.000102

F1: mean=0.9351 | std=0.0066 | var=0.000044

ROC-AUC: mean=0.9462 | std=0.0124 | var=0.000153

Average Precision: mean=0.9812 | std=0.0068 | var=0.000046

Tabella riassuntiva (metriche su test, media/std/var):


metrica	mean	std	var
accuracy	0.8995	0.0101	0.0001
f1	0.9351	0.0066	0.0000
roc_auc	0.9462	0.0124	0.0002
avg_prec	0.9812	0.0068	0.0000

#4.7 RANDOM FOREST

Si tratta di un algoritmo che costruisce una "foresta" di alberi decisionali, ciascuno dei quali viene addestrato su un sottoinsieme casuale del dataset e delle sue caratteristiche (tecnica nota come bagging). Ogni albero produce una propria previsione, e il risultato finale viene ottenuto tramite:

- **Media** nel caso di **Regressione**.
- **Moda** nel caso di **Classificazione**.

delle previsioni fatte da tutti gli alberi.



#4.7.1 DECISIONI DI PROGETTO

I **vantaggi del Random Forest** includono una solida capacità di **generalizzazione** e una buona resistenza **all'overfitting**, grazie alla combinazione di più alberi decisionali. È in grado di gestire efficacemente sia **feature numeriche che categoriali**, e si adatta bene anche a situazioni con **classi sbilanciate**.

Il modello tende a offrire **buona precisione e stabilità** nei compiti di classificazione. Inoltre, la possibilità di **addestrare gli alberi in parallelo** ne migliora le prestazioni in termini di velocità, rendendolo adatto anche in ambienti con risorse computazionali limitate.

#4.7.2 OTTIMIZZAZIONE PARAMETRI DEL CLASSIFICATORE

Per costruire il classificatore Random Forest usiamo il metodo `RandomForestClassifier()` presente nella libreria **scikit-learn** che prende 3 parametri:

- **max_depth:**
La profondità massima dell'albero decisionale.
 - Valore Alto: alberi più **complessi**, ma con rischio di **overfitting**.
 - Valore Basso: alberi più **semplici**, ma con rischio di **underfitting**.
- **random_state:**
Controlla la generazione dei numeri casuali all'interno del modello. Fornendo un valore specifico ci si assicura che l'addestramento e la previsione del modello siano riproducibili.
- **n_estimators:**
Numero di alberi decisionali.
 - Valore Alto: modello più **complesso e performante**, ma con rischio di **overfitting**.
 - Valore Basso: modello più **veloce**, ma con **performance inferiori**.

STEP #1

Per ottimizzare i parametri del modello Random Forest andiamo per prima cosa a definire un intervallo di valori da testare per ciascun parametro.

STEP #2

Utilizziamo cicli annidati per testare tutte le possibili combinazioni dei valori definiti per i parametri.

Per ogni combinazione di parametri:

- Viene creato un modello Random Forest con i parametri specificati.
- Viene eseguita una cross-validation a 5 fold tramite **StratifiedKFold**.
La cross-validation suddivide il DataSet in 5 parti (fold) addestra il modello su 4 parti e testa la sua performance sulla parte rimanente.
Questo processo viene ripetuto 5 volte, con ogni parte utilizzata una volta per il test.

STEP #3

Trovata la combinazione ottimale viene creato il modello finale.

```
=== Riepilogo Repeated Holdout (outer test) con inner 5-fold CV ===  
Accuracy:          mean=0.9281 | std=0.0117 | var=0.000137  
F1:                mean=0.8093 | std=0.0356 | var=0.001264  
ROC-AUC:           mean=0.9869 | std=0.0039 | var=0.000015  
Average Precision: mean=0.9575 | std=0.0155 | var=0.000240
```


Tabella riassuntiva (metriche su test, media/std/var):

metrica	mean	std	var
accuracy	0.9281	0.0117	0.0001
f1	0.8093	0.0356	0.0013
roc_auc	0.9869	0.0039	0.0000
avg_prec	0.9575	0.0155	0.0002

#4.7.3 VALUTAZIONE FINALE

BAR CHART DI VARIANZA E DEVIAZIONE STANDARD

Il grafico mostra che i risultati del modello sono molto stabili, con una bassa dispersione tra le diverse esecuzioni. Questo suggerisce prestazioni stabili e poco sensibili al cambio di fold.



```
=== Riepilogo Repeated Holdout (outer test) con inner 5-fold CV ===
Accuracy:      mean=0.9281 | std=0.0117 | var=0.000137
F1:            mean=0.8093 | std=0.0356 | var=0.001264
ROC-AUC:       mean=0.9869 | std=0.0039 | var=0.000015
Average Precision: mean=0.9575 | std=0.0155 | var=0.000240
```


Tabella riassuntiva (metriche su test, media/std/var):

metrica	mean	std	var
accuracy	0.9281	0.0117	0.0001
f1	0.8093	0.0356	0.0013
roc_auc	0.9869	0.0039	0.0000
avg_prec	0.9575	0.0155	0.0002

#4.8 SUPPORT VECTOR MACHINES (SVM)

L'obiettivo principale di una **Support Vector Machine (SVM)** è individuare un **iperpiano ottimale** che separi le classi (nella classificazione) o che predica i valori target (nella regressione). Le SVM puntano a **massimizzare il margine** tra l'iperpiano e i support vectors, ovvero i punti dati più vicini al confine decisionale.

Questa strategia contribuisce a rendere il modello **più robusto** e meno soggetto **all'overfitting**, migliorando così la capacità di generalizzazione su dati nuovi.



#4.8.1. DECISIONI DI PROGETTO

Questo modello è stato scelto per la sua efficacia nella **classificazione binaria**, soprattutto quando le classi risultano ben separate.

Le **SVM** si dimostrano particolarmente adatte a problemi con un **numero moderato di feature** e possono gestire **relazioni non lineari** grazie all'impiego dei **kernel**.

In particolare, è stato scelto il **kernel RBF (Radial Basis Function)**, poiché consente al modello di catturare **strutture complesse e non lineari** presenti nei dati. Questo approccio migliora la capacità della SVM di produrre una classificazione **accurata e ben generalizzabile**.

#4.8.2 OTTIMIZZAZIONE PARAMETRO GAMMA

Il parametro **gamma** è un iperparametro cruciale quando si usa il kernel RBF in un classificatore SVM.

Controlla quanto l'influenza di un singolo esempio di addestramento si estenda.

- Valori più alti di gamma rendono le decisioni più locali.
- Valori più bassi danno una maggiore influenza alle istanze circostanti.

Per trovare il miglior valore gamma

Si esegue una **ricerca stocastica** (RandomizedSearchCV) su combinazioni di iperparametri, Per ogni **combinazione**:


-Si addestra la Pipeline completa con validazione incrociata

-Si calcolano più metriche; la metrica usata per scegliere il "best" è accuracy.

#4.8.3 VALUTAZIONE FINALE

BAR CHART DI VARIANZA E DEVIAZIONE STANDARD

Il grafico indica che i risultati del modello sono molto stabili, con una bassa dispersione tra le diverse esecuzioni. Questo suggerisce che il modello ha prestazioni consistenti e affidabili.



Classification report (test):

	precision	recall	f1-score	support
0	0.86	0.88	0.87	300
1	0.53	0.49	0.51	84
accuracy			0.79	384
macro avg	0.69	0.68	0.69	384
weighted avg	0.79	0.79	0.79	384

=== Riepilogo Repeated Holdout (outer test) con inner 5-fold CV ===

Accuracy: mean=0.7945 | std=0.0076 | var=0.000058
F1: mean=0.5139 | std=0.0229 | var=0.000526
ROC-AUC: mean=0.8056 | std=0.0134 | var=0.000181
Average Precision: mean=0.5623 | std=0.0302 | var=0.000910

Tabella riassuntiva (metriche su test, media/std/var):

metrica	mean	std	var
accuracy	0.7945	0.0076	0.0001
f1	0.5139	0.0229	0.0005
roc_auc	0.8056	0.0134	0.0002
avg_prec	0.5623	0.0302	0.0009

Process finished with exit code 0


#4.9 NEURAL NETWORK

Le **reti neurali** sono modelli ispirati al funzionamento del cervello umano, composti da neuroni artificiali interconnessi.

Ogni **neurone** riceve degli **input**, li **pesa** in base alla loro **importanza**, li **somma** e confronta il risultato con una **soglia di attivazione**.

Se il valore supera tale soglia, il neurone si attiva e trasmette l'informazione agli altri neuroni.

In questo modo, la rete è in grado di elaborare stimoli complessi e apprendere relazioni non lineari tra i dati.



#4.9.1 DECISIONI DI PROGETTO

Il modello è stato scelto per la sua capacità di affrontare **problemi di apprendimento profondi e complessi** e per la sua capacità di raggiungere **prestazioni di livello superiore** in termini di accuratezza e precisione.

Ho scelto di definire una rete neurale sequenziale con due livelli:

- **1° LIVELLO:**
64 neuroni nascosti, utilizza la funzione di attivazione **ReLU**;
- **2° LIVELLO:**
1 singolo neurone con una funzione di attivazione **sigmoidale**, che produce un valore compreso tra 0 e 1 per la classificazione binaria.

#4.9.2 CREAZIONE MODELLO E ADDESTRAMENTO

STEP #1

Definiamo la funzione `create_model()` che costruisce e restituisce un modello di rete neurale creato con **Keras**:

1. Usiamo il modello sequenziale, che permette di impilare i livelli uno dopo l'altro.
2. Aggiungiamo un **fully connected layer** di 64 unità nascoste che usano la **ReLU - Rectified Linear Unit** come funzione di attivazione dei neuroni.
3. Aggiungiamo un **fully connected layer** di una sola unità che usa la **sigmoid** come funzione di attivazione dei neuroni per comprimere l'output in un intervallo tra 0 e 1.
4. La funzione termina con la compilazione del modello, utilizzando la funzione **binary_crossentropy**, che è appropriata per problemi di classificazione binaria e l'ottimizzatore **adam** che viene utilizzato per addestrare la rete, ed è noto per la sua efficacia in una varietà di scenari.

STEP #2

Si crea quindi un'istanza del modello e inizia l'addestramento sui dati.

I parametri in input sono:


- **neurons:**
numero di neuroni nel layer denso nascosto.
- **activation:**
funzione di attivazione del layer nascosto (es. relu, tanh).
- **lr:**
learning rate dell'ottimizzatore (Adam).
- **epochs:**
Specifica quante volte l'intero TrainingSet verrà utilizzato per aggiornare i pesi del modello.
 - Ho scelto di addestrare il modello per 40/50 epochs, dato che maggiori epochs potrebbero consentire al modello di adattarsi meglio ai dati di addestramento, ma potrebbero anche portare all'**overfitting**.
- **batch_size:**
Definisce la dimensione del batch, ovvero quante istanze di addestramento vengono utilizzate prima di aggiornare i pesi del modello.
 - Ho scelto di utilizzare un batch di dimensione 64 e 32, perché rappresenta un **compromesso** tra l'accuratezza del modello e l'efficienza di addestramento. Potrebbe fornire un'adeguata quantità di dati per apprendere modelli complessi senza richiedere troppo tempo computazionale.

```
param_grid = [  
    {"neurons": 32, "activation": "relu", "lr": 1e-3, "batch_size": 32, "epochs": 40},  
    {"neurons": 64, "activation": "relu", "lr": 1e-3, "batch_size": 32, "epochs": 40},  
    {"neurons": 64, "activation": "relu", "lr": 5e-4, "batch_size": 64, "epochs": 50},  
    {"neurons": 64, "activation": "relu", "lr": 5e-4, "batch_size": 64, "epochs": 50},  
    {"neurons": 128, "activation": "relu", "lr": 1e-3, "batch_size": 64, "epochs": 50},  
    {"neurons": 64, "activation": "tanh", "lr": 1e-3, "batch_size": 32, "epochs": 40},  
]
```

#4.9.3 VALUTAZIONE FINALE

BAR CHART DI VARIANZA E DEVIAZIONE STANDARD

Il Bar Chart di Varianza e Deviazione Standard mostra una varianza di circa 0.0001 e una deviazione standard di 0.0097, indicando che le prestazioni del modello sono costanti e affidabili.



Classification report (test):

	precision	recall	f1-score	support
0	0.98	0.95	0.96	300
1	0.84	0.93	0.88	84
accuracy			0.95	384
macro avg	0.91	0.94	0.92	384
weighted avg	0.95	0.95	0.95	384

=== Riepilogo Repeated Holdout (outer test) con inner 5-fold CV ===

Accuracy: mean=0.9531 | std=0.0097 | var=0.000094
F1: mean=0.8924 | std=0.0218 | var=0.000475
ROC-AUC: mean=0.9771 | std=0.0094 | var=0.000088
Average Precision: mean=0.9324 | std=0.0293 | var=0.000861

Tabella riassuntiva (metriche su test, media/std/var):

metrica	mean	std	var
accuracy	0.9531	0.0097	0.0001
f1	0.8924	0.0218	0.0005
roc_auc	0.9771	0.0094	0.0001
avg_prec	0.9324	0.0293	0.0009

#4.10 CONCLUSIONI

Nella seguente tabella sono elencate le metriche usate per confrontare i modelli.

	ACCURATEZZA	VARIANZA	DEV. STANDARD	F1-SCORE	AVERAGE-PRECISION	AUC
K-NN	0.8995	0.0001	0.0101	0.9351	0.98	0.946
RANDOM FOREST	0.9281	0.0001	0.0117	0.8093	0.96	0.987
SVM	0.7945	0.00006	0.0076	0.5139	0.56	0.805
NEURAL NETWORK	0.9531	0.00009	0.0097	0.8924	0.93	0.977

CONCLUSIONI DALLA TABELLA

- **Neural Network è il miglior modello**
 - Ha la **maggiore accuratezza (0.95)** e il secondo **miglior F1-score (0.8924)**, il che indica un'eccellente capacità di classificazione e più stabile rispetto agli altri modelli.
- **Random Forest e KNN sono molto validi**
 - Entrambi hanno una buona **accuratezza**, con KNN migliore nell'**F1-score** perciò **più stabile**.
- **SVM è il meno performante**
 - Ha la **minor accuratezza (0.79)** e il **minore F1-score (0.51)**.

CONCLUSIONE GENERALE

Considerando l'importanza di una diagnosi accurata nel contesto medico, ho quindi deciso di adottare il modello di **Neural Network** per la classificazione dei tumori, garantendo così un'analisi più precisa e affidabile per supportare il processo diagnostico.

La tabella riporta le **prestazioni** dei modelli valutate su **più test set**.
Per ogni metrica mostriamo media (**mean**), deviazione standard (**std**) e varianza (**var**) calcolate sui diversi run.

KNN:

```
Tabella riassuntiva (metriche su test, media/std/var):  
metrica  mean   std    var  
accuracy 0.8995 0.0101 0.0001  
    f1 0.9351 0.0066 0.0000  
    roc_auc 0.9462 0.0124 0.0002  
    avg_prec 0.9812 0.0068 0.0000
```

Prestazioni molto alte su F1 e Average Precision, con buona Accuracy e ROC-AUC. Deviazioni standard basse: modello stabile.

Random Forest:

```
Tabella riassuntiva (metriche su test, media/std/var):  
metrica  mean   std    var  
accuracy 0.9281 0.0117 0.0001  
    f1 0.8093 0.0356 0.0013  
    roc_auc 0.9869 0.0039 0.0000  
    avg_prec 0.9575 0.0155 0.0002
```

Accuracy elevata e ROC-AUC tra le più alte (forte capacità discriminativa). F1 più bassa rispetto a KNN: con una taratura della soglia potrebbe crescere. Stabilità buona (std ridotte).

SVM:

```
Tabella riassuntiva (metriche su test, media/std/var):  
metrica  mean   std    var  
accuracy 0.7945 0.0076 0.0001  
    f1 0.5139 0.0229 0.0005  
    roc_auc 0.8056 0.0134 0.0002  
    avg_prec 0.5623 0.0302 0.0009
```

Prestazioni sensibilmente inferiori su tutte le metriche e maggiore variabilità. Può fungere da baseline.

Neural Network:

```
Tabella riassuntiva (metriche su test, media/std/var):  
metrica  mean   std    var  
accuracy 0.9531 0.0097 0.0001  
    f1 0.8924 0.0218 0.0005  
    roc_auc 0.9771 0.0094 0.0001  
    avg_prec 0.9324 0.0293 0.0009
```

Migliore Accuracy complessiva e ROC-AUC molto alta; F1 e AP elevate e stabili. Buon compromesso generale tra discriminazione e qualità delle predizioni positive.

#5 APPRENDIMENTO NON SUPERVISIONATO:

CLUSTERING

Questa tecnica permette di **individuare raggruppamenti naturali** all'interno dei dati anche in **assenza di etichette di classe**.

Ciò può rivelare **relazioni nascoste** tra le risposte al questionario, offrendo una prospettiva alternativa sulla struttura e sulla distribuzione del dataset.

Il clustering può essere di due tipi:

- **Hard Clustering:**
Prevede l'assegnazione statica di ciascun esempio a una classe di appartenenza.
- **Soft Clustering:**
Utilizza distribuzioni di probabilità per assegnare le classi associate a ciascun esempio.

#5.1 DECISIONI PROGETTUALI

Questa tecnica è stata scelta per raggruppare i pazienti in categorie basate sulle caratteristiche presenti nel file 'breast_msk_2018_clinical_data.csv'.

L'obiettivo è individuare dei **cluster**, ovvero gruppi di esempi simili a **centroidi** calcolati in modo automatico.

L'utilizzo di questa tecnica nel progetto mira a vedere la distribuzione dei pazienti nei vari cluster che in questo caso non è perfettamente bilanciata. Ciò potrebbe influire su alcuni algoritmi di apprendimento supervisionato. La questione relativa allo sbilanciamento delle classi e alla sua possibile soluzione viene trattata nel capitolo dell'apprendimento supervisionato. In più può servire per creare una nuova colonna da aggiungere alle features relative ai dati di ciascun paziente, in un nuovo file chiamato 'breast_msk_2018_clinical_data-clusters.csv'.

Questo potrebbe aprire nuove prospettive sulla varietà delle risposte e potenzialmente portare a nuove intuizioni sul cancro al seno e contribuire a una diagnosi più accurata e comprensiva.

Nel nostro caso, ho scelto di utilizzare una tecnica di **Hard Clustering**, in particolare il **k-means**, implementato tramite la libreria **Scikit-learn**.

#5.2 K-MEANS

K-Means è un algoritmo di **clustering** che suddivide un insieme di dati in K cluster, dove K è un valore predefinito. L'obiettivo è **raggruppare i dati** in modo tale che gli elementi all'interno di uno stesso cluster siano quanto più **simili** tra loro, mentre risultino distinti rispetto agli elementi appartenenti ad altri cluster.

L'algoritmo cerca di **minimizzare la distanza complessiva** tra ciascun punto e il centroide del proprio cluster, ottimizzando così la compattezza interna dei gruppi formati.

Ho scelto il Kmeans per:

- **Verifica di coerenza** con gli esiti clinici:

Confrontando i cluster con "Overall Survival Status" (tabella incrocio e ARI ≈ 0.21), si valuta quanto i gruppi riflettano outcome noti: qui la coerenza è debole-moderata, quindi i cluster catturano segnali parzialmente indipendenti dalla sola sopravvivenza (informazione complementare).


STEP #1

Uno dei problemi principali del KMeans è trovare il numero ideale di cluster da fornire in input all'algoritmo. Ho dovuto, per prima cosa, determinare il numero ottimale di cluster. A tal scopo, ho utilizzato il **Metodo del Gomito** (Elbow Method):

- Sull'asse **Y** rappresentiamo il **WCSS - Within-Cluster Sum of Squares**, che misura la compattezza dei cluster.
- Sull'asse **X** rappresentiamo il numero di cluster **K**.
 - Il punto ottimale viene scelto osservando dove il WCSS **smette di diminuire significativamente**, formando un angolo simile a un "gomito".

```
# Calcolo WCSS per diversi valori di K
wcscs = []
silhouette_scores = []
k_range = range(1, 11)

for k in k_range:
    kmeans = KMeans(n_clusters=k, n_init=10, random_state=42)
    kmeans.fit(X_scaled)
    wcscs.append(kmeans.inertia_)
    # Il silhouette score non può essere calcolato per k=1
    if k > 1:
        silhouette_scores.append(silhouette_score(X_scaled, kmeans.labels_))
    else:
        silhouette_scores.append(0) # Per k=1 impostiamo il silhouette score a 0
```



STEP #2

Dall'analisi precedente, il valore di **K ottimale è risultato essere**

2. Addestro quindi il modello sui 2 cluster.

I parametri scelti per la configurazione del modello indicano:

- **n_clusters:**
Il numero dei cluster in cui dividere i dati del DataSet.
Nel mio caso avrà valore pari a 2.
- **n_init:**
Specifica il numero di volte che l'algoritmo sarà eseguito con diverse inizializzazioni casuali dei centroidi.
 - Un valore maggiore aumenta le probabilità di ottenere una soluzione di migliore qualità a scapito di un maggior tempo di calcolo.**Ho scelto un valore non troppo alto, ma sufficiente per massimizzare la qualità dell'output, quindi 10.**
- **random_state:**
Questo parametro controlla la riproducibilità dei dati.
 - Fissandolo ad un valore alto, il modello fornirà gli stessi risultati quando viene addestrato con gli stessi dati.**Ho fissato il suo valore a 42.**

#5.3 VALUTAZIONE FINALE DEL MODELLO

Sono state valutate le prestazioni del modello utilizzando due metriche:

- **WCSS (Within-Cluster Sum of Squares):**

Calcola la somma dei quadrati delle distanze di ogni punto rispetto al proprio centroide.

- Un valore più basso di WCSS indica una maggiore coesione all'interno dei cluster.

- **Silhouette Score:**

Valuta quanto un punto sia vicino al proprio cluster rispetto ai cluster vicini.

- **Valori vicini a 1:** Cluster ben separati.
- **Valori vicini a 0:** Cluster che si sovrappongono.
- **Valori negativi:** Assegnazioni errate dei punti ai cluster.

-WCSS: 5497.60

-Silhouette Score: 0.4911

	WITHIN-CLUSTER SUM OF SQUARES	SILHOUETTE SCORE
K-MEANS	5497.60	0.4911

CONCLUSIONE GENERALE

Con uno Silhouette Score pari a 0.4911 è possibile affermare che il clustering è **buono**, ma non perfettamente separato.

Da ciò ho dedotto che potrebbero esserci sovrapposizioni tra i cluster e quindi deduciamo che il dataset **non è naturalmente divisibile in due gruppi ben distinti**. Questa sovrapposizione può derivare da dati rumorosi e ciò potrebbe aver creato

#6 CONCLUSIONE

In questo progetto ho esplorato il tema delicato del cancro al seno da diverse prospettive, applicando tecniche di intelligenza artificiale per analizzare e classificare i dati relativi a questa patologia.

L'obiettivo prefissato era quello di sviluppare uno strumento di supporto alla diagnosi, in grado di predire lo stato di vita o di morte dei pazienti attraverso l'utilizzo dell'AI. I risultati ottenuti confermano la validità di questo approccio, evidenziando come l'intelligenza artificiale possa rappresentare un valido ausilio nel processo diagnostico.

#6.1 POSSIBILI SVILUPPI

Questo progetto potrebbe avere una serie di sviluppi futuri per migliorare la sua efficacia e l'applicazione pratica delle scoperte.

Alcune possibili direzioni per lo sviluppo futuro possono essere:

- **L'espansione del DataSet:**
Banalmente raccogliere dati aggiuntivi e aumentare le dimensioni del DataSet potrebbe migliorare ulteriormente le prestazioni dei modelli.
Un DataSet più grande può fornire maggiore variabilità nei dati e consentire una migliore generalizzazione.
- **L'integrazione con l'interpretazione medica:**
Ovvero collegare le scoperte dei modelli di apprendimento supervisionato con specialisti in ambito medico che potrebbero aiutarci ad indirizzare meglio il nostro lavoro.